

并行程序设计实验

## 实验 3 文档分类向量化

联系方式: [NJU-TJL@outlook.com](mailto:NJU-TJL@outlook.com)

## 目录

实验 3 文档分类向量化	3
一、 实验设计	3
1. MPI 实现部分	3
1) 整体思路	3
2) 读取字典，构建哈希表	3
3) 读取文件目录，识别文档	4
2. OpenMP 实现部分	4
1) 串行程序思路	4
2) 并行化思想	4
二、 实验结果	4
1. 运行环境	5
2. MPI 实现运行结果	5
3. OpenMP 实现运行结果	6
4. 结果分析	7
三、 实验中遇到的问题及解决办法	7
1. MPI 进程个数随机	7
2. 处理字典内容时出现问题	7
3. 文件名顺序问题	8
四、 实验总结	8
五、 参考文献及资料	8

# 实验 3 文档分类向量化

## 一、实验设计

### 1. MPI 实现部分

MPI 程序的大体框架参考了讲义给的《MPI 与 OpenMP 并行程序设计：C 语言版》的第 9 章内容。通过阅读和理解，掌握了其中给出的管理者/工人模式的并行程序大致思路，而剩下的一些内容如（如读取文件目录、构造哈希等等），还需要自己完善。故此次实验先完成了 MPI 部分并行程序。下面对整体思路和一些具体实现细节进行阐述。

#### 1) 整体思路

原书已给出较为完整的设计思路、管理者/工人进程伪代码和 C 语言代码。故这里不再用过多篇幅赘述，仅仅说一下在阅读之后自己的一点理解。

首先，总体上的任务是读取指定目录下的文本文件及字典文件，然后统计每个文档中字典中的每个词的出现个数（即构成“文档向量”），并写入一个结果文件。

此任务中，任务的数目在编译时无法确定，而各个任务之间不需要通信，完成不同任务处理每个文档所花费的时间差异可能会较大，因为文档的大小可能有很大的不同。所以这里采用的是管理者/工人模式进行。

管理者负责：①读取文件目录，获取待处理的文件是哪些。②分配文档处理任务给工人进程，负责总体调度（比如什么时候终止）。③接收工人进程处理结果（即文档向量），并汇总输出到结果文件。

工人负责：①0 号工人负责读取字典，然后广播给所有工人。②从字典文件构造哈希表，便于后面的文档向量化处理。③完成管理者指定的文档处理任务，并传送给管理者处理结果（即文档向量）。

#### 2) 读取字典，构建哈希表

首先，0 号工人进程需要读取字典文件内容，并且广播给所有工人。实现中，0 号工人调用 `readAll` 函数将字典文件的内容一次性读入到 `buffer` 中，然后在广播给所有工人。之后，每个工人进程都调用 `make_dict_Hash` 函数，根据字典文件内容来构建 Hash 表。这种方式相比于另一种可能的实现（每个工人进程都各自读取字典文件内容），是更高效的。因为读取同一个文件，涉及文件 I/O 操作，而且可能还有占用问题，往往较慢。而进程间广播速度则会更快一些。

对于 Hash 表的构建，这里的实现如下。首先，这里构建了一个 Hash 结构，输入一个字符串（字典中的某个词），可以在较低（接近常数）的复杂度内返回一个整数，表示在字典中的下标，即这个词是字典中的第几个词。

对字符串的 Hash 函数有很多，这里采用了 [P.J.Weinberger 提出](#) 的一个函数，输入一个字符串，Hash 结果为一个小于等于 `0x3fff` 的整数。而 Hash 表采用的是链地址法构建，即一个大小为 `0x3fff+1` 的数组。这样即可解决 Hash 地址冲突的问题（冲突则放到该地址的同一个链表上）。其中存储着链表头节点，每个链表上才是存储真正的 Hash 节点（即字符串的内容和对于的字典下标值）。

有了 Hash 表之后，文档向量化就变得简单：读入文档中的一个单词，查 Hash，获得单

词在字典中的下标，表示文档向量的数组对应下标的元素加 1 即可。

### 3) 读取文件目录，识别文档

管理进程需要在用户给出的目录下识别出  $n$  个文本文档。这里实现了 `get_names` 函数来完成这一功能。即：在指定目录下，识别出所有普通文件，构建一个记录文件路径的数组，且返回文件个数。

这里主要用到了 Linux 下提供的 `dirent.h` 中的相关 API 函数来完成，用类似读取文件的方式来读取目录。首先，需要使用 `opendir` 函数打开目录，然后可以使用 `readdir` 对目录进行遍历，访问其中的文件、文件夹等内容。这里首先进行了一次遍历，得到文件总数。分配好数组空间后，第二次遍历记录下所有文档的路径，存在数组中，最后再对这个数组按照文件路径排个序。

## 2. OpenMP 实现部分

实现 OpenMP 程序，首先实现一个串行版本。而在 MPI 程序的实现基础上，实现串行程序则非常简单。一些模块的操作，比如读取字典文件、构造 Hash、读取目录识别文档、文档向量写入结果文件等，都以函数的形式封装在了 `MyUtils.c` 中，所以串行程序只需将这些过程组合起来即可。

### 1) 串行程序思路

串行程序实现非常简单，相比 MPI 实现少了很多进程通信、任务分配等的额外操作。

主要处理步骤如下：

- a) 读取字典文件；
- b) 构建哈希表；
- c) 读取目录，识别文档文件，数组中记录下所有文档的路径，以及文档个数  $n$ ；
- d) 用一个 for 循环，依次对  $n$  个文档进行向量化；
- e) 文档向量写入结果文件。

### 2) 并行化思想

串行程序中，程序主要执行过程在上述过程的 d)，而这一步中，是一个 for 循环的过程，非常适合并行化。所以这里的并行化非常简单，只需要在 for 循环前加一行 `"#pragma omp parallel for"` 即可。

## 二、实验结果

注：关于程序正确性的验证。

测试时使用了一些小规模字典文件（比如只含有 a 开头的前 10 个单词）和几个小的文档（内容只有几个单词），OpenMP 和 MPI 程序的测试结果均为正确。此外，对于老师给定的样例（100 个文档），将 OpenMP 和 MPI 程序输出的结果文件使用 Linux 终端下的 `diff` 命令进行比对，发现完全一致，所以基本可以确定 OpenMP 和 MPI 所实现的文档向量化程序逻辑无误。

## 1. 运行环境

物理机 CPU: Intel i5-7200U (双核), 内存 16GB

虚拟机: CPU 分配 2 个核, 内存 4GB

虚拟机系统环境: Ubuntu 16.04 (64 位版本)、gcc version 5.4.0 20160609、mpicc for MPICH version 3.3.2

## 2. MPI 实现运行结果

使用如下命令编译源代码:

```
mpicc -o main main.c MyUtils.c
```

再按如下格式运行可执行文件:

```
mpirun -np 2 ./main ./test/ dict.txt result.txt
```


说明: ①"2"表示进程个数, 最小为 2; ②"./test/"代表文档所在目录, 末尾需要有"/"; ③"dict.txt"代表字典文件路径; ④"result.txt"代表结果文件路径。

程序会在终端打印输出运行时间, 且生成存放文档向量信息结果文件。

为减少误差, 这里使用了 shell 脚本进行 10 轮实验 (程序同目录下, 终端输入"./run.sh"即可执行脚本)。由于这里的 MPI 程序采用了管理者/工人模式, 实际“干活”的是工人进程, 所以这里以工人进程的个数来进行实验, 计算加速比。每一轮中, (工人) 进程数分别取 1、2、3、4、8、16 和 32。最终, 可得到数据如下表:

进程数 (工人进程)		1	2	3	4	8	16	32
执行时间 (单位: s)	Round 1	0.165	0.111	0.144	0.168	0.341	0.665	1.697
	Round 2	0.171	0.106	0.111	0.149	0.400	0.764	1.434
	Round 3	0.141	0.101	0.145	0.144	0.388	0.761	1.321
	Round 4	0.156	0.128	0.116	0.136	0.364	0.787	1.098
	Round 5	0.138	0.113	0.115	0.256	0.343	0.674	1.440
	Round 6	0.130	0.105	0.138	0.225	0.335	0.694	1.191
	Round 7	0.136	0.117	0.105	0.209	0.299	0.643	1.402
	Round 8	0.156	0.106	0.141	0.234	0.428	0.917	1.411
	Round 9	0.164	0.102	0.133	0.127	0.335	0.629	1.166
	Round 10	0.135	0.102	0.128	0.223	0.360	0.605	1.262
平均时间		0.149	0.109	0.128	0.187	0.359	0.714	1.342
加速比		1.00	1.37	1.17	0.80	0.42	0.21	0.11

将加速比绘制成柱状图如下:



3. OpenMP 实现运行结果

使用如下命令编译源代码：

```
gcc -fopenmp -o main main.c MyUtils.c
```

再按如下格式运行可执行文件：

```
./main 4 ./test/ dict.txt result.txt
```


说明：①"4"表示进程个数；②"./test/"代表文档所在目录，末尾需要有'/')；③"dict.txt "代表字典文件路径；④"result.txt"代表结果文件路径。

程序会在终端打印输出运行时间，且生成存放文档向量信息结果文件。

为减少误差，这里使用了 shell 脚本进行 10 轮实验（程序同目录下，终端输入"./run.sh"即可执行脚本）。每一轮中，线程数分别取 1、2、4、8、16 和 32。最终，可得到数据如下表：

线程数		1	2	4	8	16	32
执行时间 (单位：s)	Round 1	0.104	0.082	0.077	0.088	0.073	0.073
	Round 2	0.102	0.078	0.069	0.082	0.082	0.111
	Round 3	0.122	0.082	0.077	0.085	0.076	0.079
	Round 4	0.108	0.078	0.077	0.090	0.075	0.076
	Round 5	0.111	0.085	0.077	0.091	0.072	0.083
	Round 6	0.102	0.081	0.096	0.079	0.095	0.085
	Round 7	0.104	0.079	0.088	0.077	0.075	0.073
	Round 8	0.103	0.084	0.066	0.082	0.068	0.075
	Round 9	0.119	0.079	0.069	0.078	0.067	0.078
	Round 10	0.091	0.079	0.067	0.074	0.072	0.075
平均时间		0.107	0.081	0.076	0.083	0.076	0.081
加速比		1.00	1.32	1.40	1.29	1.41	1.32

将加速比绘制成柱状图如下：



## 4. 结果分析

本次实验中，由于采用的 Hash 方法较为高效，所以总的计算时间不是很大，总体来看加速比没有非常接近 2，并行额外开销相比之下比较大。这一点在 MPI 实现中有很大的体现。

MPI 实现的实验结果符合预期，即：随着进程数增加，加速比逐渐增大到最大值，再随着进程数的增大，加速比下降。当进程数增加，越来越充分利用 2 个物理 CPU 核的并行资源，加速比也就接近于最高。而进程数增加到一定程度，物理 CPU 核有限的，再增加线程数也无法从物理上增加程序运行的并行程度，反而因为进程数的增加，带来进程通信和管理等的额外开销，所以使得运行时间增加，加速比下降。

同时，后期下降的幅度很大，显示出增加进程带来的额外开销增长较为明显。在 MPI 程序中，进程通信的开销主要体现在工人进程之间广播字典文件内容，字典文件大小为 38.9k，广播这一内容无疑是需要很大的开销。而 Bcast 的开销与进程个数是线性关系，当进程大到一定程度后，这一开销成为主要耗时。进程数从 4、8、16 到 32 时，加速比每次刚好差不多是前一次的一半，正好可以验证这一想法。

而 OpenMP 是利用多线程来加速程序执行，在共享内存系统上运行。而线程与进程对比下，线程是更轻量级的，可以提供更细粒度的并行，且通信等的额外开销更小（线程不用完全复制出一整个独立的内存空间，多个线程可以共用一个；进程则是每个进程有自己独立的内存空间）。而本次实验中 OpenMP 程序没有涉及线程间数据通信，所以自然结果中 OpenMP 显示出的并行额外开销小，即随着线程增大，加速比没有明显下降。

## 三、 实验中遇到的问题及解决办法

### 1. MPI 进程个数随机

每次生成的进程个数随机，比如指定 5 个进程时，虽然 `MPI_Comm_size()` 返回的是 5，但是如果每个进程都 `printf` 输出，每次是 1~5 随机个数的进程会执行输出。

**解决：**

检查和比对 MPI 程序代码结构是否完整，发现结尾处缺少 `"MPI_Finalize();"`，补上之后即程序正常。

### 2. 处理字典内容时出现问题

在生成 Hash 表的函数 `make_dict_Hash` 中，使用了 `"strtok(dict_buffer, " \n\t");"` 这一函数对字典内容按照空白符进行分割，分割出一个个的单词。直接输出分割出的单词显示正常，但是计算文档向量时，没有按照预期计数。

**解决：**

使用 `strcmp` 将分割出的单词与指定的字符串比较（比如 `"a"`），发现匹配失效，但是 `printf` 打印出来看起来是一样的。所以猜测可能是存在不可见字符，通过 `strlen` 查看长度发现果然长度不对。之后输出字符串中 ASCII 值，发现分割出的单词末尾都会多出一个 ASCII 值为 13 的字符，即 `'\r'`。所以，这是由于不同平台文档换行回车格式不同导致的，所以 `strtok` 函数的第二个参数应该为 `"\r\n\t"`。

### 3. 文件名顺序问题

在 `get_names` 函数中，获取该目录下的所有文件的文件名之后，发现是乱序的。查阅[相关博客](#)后，得知是因为 `readdir` 的读取顺序，是按照在磁盘的索引顺序 `d_off` 来排序的。

#### 解决：

使用库函数 `qsort` 来对存储文件名的数组排序。自定义排序规则：先按字符串长度排序，长度相等情况下，调用 `strcmp` 进行排序。这样得出的文件名顺序就是按照 `doc0.txt`、`doc1.txt`、`doc2.txt`、……、`doc99.txt` 的顺序。

## 四、实验总结

- OpenMP 很多时候简单高效。特别适合在需要共享内存场景下，处理计算主体 `for` 循环部分的并行。使用 OpenMP 可以较为方便地从串行代码中修改得到并行代码，但是操作的灵活性不如 MPI，会有更多的局限性，适用面不如 MPI 广，比如无法在计算机集群上使用。
- MPI 程序中，在进程数增大到一定程度时，我们需要考虑到进程通信带来额外开销的影响。比如本次实验中，计算处理时间不长（因为使用的哈希效率较高），但是相比之下并行额外开销较大。
- 在本次实验中，虽然 OpenMP 执行效果和加速效果都好于 MPI，但这并不说明本次实验中的 OpenMP 完胜 MPI。它们各自适用的地方有不同。比如，这里的 OpenMP 实现在负载均衡方面做得就不够好，没有采用灵活的任务划分方式，而是一开始就指定文档给对应线程。如果文档之间大小差异较大，就可能出现有些线程早早就完成任务，从而空闲，这种情况下就会需要特别考虑负载均衡。所以 MPI 实现中的管理者/工人模式则变得非常有用。如果处理的总数据量很大，那么 MPI 中的并行额外相对就较小，而负载均衡的重要性就显现出来了，所以那种场景下 MPI 程序的表现可能会更加优秀。

## 五、参考文献及资料

[1] Quinn M，奎因，陈文光，et al. MPI 与 OpenMP 并行程序设计:C 语言版[M]. 清华大学出版社, 2004.

[2] C 语言中的 `dirent.h` 说明\_hello188988 的专栏-CSDN 博客.

<https://blog.csdn.net/hello188988/article/details/47711217>

[3] Linux 上 `readdir` 遍历文件夹按文件名排序\_krens 的专栏-CSDN 博客\_readdir 函数按时间排序. [https://blog.csdn.net/krens/article/details/78365382?utm\\_source=blogxgwz4](https://blog.csdn.net/krens/article/details/78365382?utm_source=blogxgwz4)